Scikit-learn

January 16, 2021

1 Uczenie maszynowe w Pythonie

1.0.1 Ekosystem

- pandas
- numpy
- scikit-learn
- matplotlib, seaborns, bokeh, pyplot

1.0.2 Co jeszcze:

- pytorch
- tensorflow (keras)

1.1 Numpy

- biblioteka, która jest podstawą pandasa, scikit-learn i pozostałych bibliotek.
- Wprowadza nowy typ danych tablice wielowymiarowe: np.array.
- Ponadto dostarcza wydajne funkcje, które operują na np.array

```
[203]: import numpy as np
    a = np.array([1, 2, 3])
    print(a)
[1 2 3]
```

```
[208]: a = np.array([[1, 2, 3], [4, 5, 6]])
a
```

```
[208]: array([[1, 2, 3], [4, 5, 6]])
```

```
[213]: a[0][1:3]
```

[213]: array([2, 3])

```
[200]: np.log(a)
```

```
[200]: array([[0.
                         , 0.69314718, 1.09861229],
              [1.38629436, 1.60943791, 1.79175947]])
[201]: a.shape
[201]: (2, 3)
[217]: a[0][0] = '10'
       a
[217]: array([[10, 2, 3],
              [4, 5, 6]
      https://numpy.org/doc/1.19/user/tutorials_index.html
      1.1.1 Scikit-learn
         • prosta obsługa
         • kompaktybilne z innymi bibliotekami
         • Darmowe, open-source (BSD)
      1.1.2 Scikit-learn
         • przetwadzanie danych
         • modele
         • trening i ewaluacja
[218]: import sklearn
       import pandas as pd
[219]: from sklearn import datasets
[224]: data = datasets.load_iris()
       from sklearn.model_selection import train_test_split
       features = pd.DataFrame(data['data'], columns=data['feature_names'])
       labels = pd.Series(data['target'])
       features.head()
       labels.sample(10)
[224]: 97
       29
              0
       123
              2
       98
              1
       83
              1
       125
              2
```

```
14 0
85 1
74 1
1 0
dtype: int64
```



```
 \begin{bmatrix} 2 & 1 & 0 & 2 & 0 & 2 & 0 & 1 & 1 & 1 & 2 & 2 & 1 & 1 & 1 & 1 & 0 & 1 & 1 & 0 & 0 & 2 & 1 & 0 & 0 & 2 & 0 & 0 & 1 & 1 & 0 & 2 & 2 & 2 & 1 & 0 \\ 2 & 1 & 1 & 2 & 0 & 2 & 0 & 0 & 1 & 2 & 2 & 2 & 2 \end{bmatrix}    \begin{bmatrix} 2 & 1 & 0 & 2 & 0 & 2 & 0 & 0 & 1 & 1 & 1 & 2 & 2 & 2 & 2 & 1 & 0 & 0 & 2 & 1 & 0 & 0 & 2 & 0 & 0 & 1 & 1 & 0 & 2 & 2 & 2 & 1 & 0 \\ 1 & 1 & 1 & 2 & 0 & 2 & 0 & 0 & 1 & 2 & 2 & 2 & 2 \end{bmatrix}
```

Zadanie 1: znajdz najlepsze k w algorytmie KNN

1.2 Przetwarzanie danych

```
[38]: from sklearn import preprocessing
```

1.2.1 Co może wchodzić w skład przetwarzania

- skalowanie (StandardScaler, MinMaxScaler, MaxAbsScaler, Normalizer)
- redukcja wymiaru (PCA)
- enkodowanie (LabelEncoder)
- Bardzo żadko zdarza się, żeby dane były gotowe do treningu.
- Najcześciej musimy je przetworzyć, aby móc je wykorzystać i/lub uzyskać lepszy wynik.
- scikit-learn potrafi operować wyłącznie na danych numerycznych.

1.2.2 Transformery:

- służą do przetwarzania danych
- maja metody: fit, transform i fit_transform.

```
[42]: features.head()
```

```
[42]:
        sepal length (cm) sepal width (cm) petal length (cm) petal width (cm)
     0
                       5.1
                                         3.5
                                                            1.4
                                                                              0.2
     1
                       4.9
                                         3.0
                                                            1.4
                                                                              0.2
      2
                       4.7
                                         3.2
                                                            1.3
                                                                              0.2
      3
                       4.6
                                                            1.5
                                                                              0.2
                                         3.1
      4
                       5.0
                                         3.6
                                                            1.4
                                                                              0.2
[53]: | scaler = preprocessing.StandardScaler()
      scaler.fit(train x)
      train_scaled = scaler.transform(train_x)
      train_scaled[:5]
[53]: array([[-0.31699245, -1.33490866, 0.07470002, -0.13206311],
             [2.06897222, -0.15774053, 1.2920336, 1.40653626],
             [0.47832911, 0.54856035, 0.51736677, 0.50901996],
             [-0.43060981, -1.57034229, 0.01936667, -0.13206311],
             [0.47832911, -0.86404141, 0.62803346, 0.76545319]])
[62]: print('Mean:', scaler.mean)
      print()
      print('Scale:', scaler.scale_)
     Mean: [5.879 3.067 3.765 1.203]
     Scale: [0.88014715 0.42474816 1.80722854 0.77993013]
[61]: model = KNeighborsClassifier(5)
      model.fit(train_scaled, train_y)
      predictions = model.predict(scaler.transform(test_x))
      accuracy_score(predictions, test_y)
[61]: 0.96
     Zadanie 2
[64]: from sklearn.datasets import load_wine
      wine = load_wine()
      train_x, test_x, train_y, test_y = train_test_split(wine.data, wine.target,_u
      →test size=0.2, random state=0)
      model = KNeighborsClassifier(5)
      model.fit(train_x, train_y)
      predictions = model.predict(test_x)
      accuracy_score(predictions, test_y)
```

[80]: 0.80555555555556

```
[82]: scaled_train_x = scaler.fit_transform(train_x)
  decomposed_train_x = pca.fit_transform(scaled_train_x)

model = KNeighborsClassifier(5)
  model.fit(decomposed_train_x, train_y)

predictions = model.predict(
    pca.transform(
        scaler.transform(test_x)
    )
  )
  accuracy_score(predictions, test_y)
```

[82]: 0.97222222222222

1.2.3 Pipeline

```
accuracy_score(predictions, test_y)
 [82]: 0.97222222222222
[89]: from sklearn.pipeline import make_pipeline
       pipeline = make_pipeline(StandardScaler(), PCA(2), KNeighborsClassifier(5))
       pipeline.fit(train_x, train_y)
       predictions = pipeline.predict(test_x)
       accuracy_score(predictions, test_y)
[89]: 0.97222222222222
[189]: pipeline.steps
[189]: [('columntransformer-1',
         ColumnTransformer(remainder='passthrough',
                           transformers=[('encoder', LabelEncoder(), 'Sex')])),
        ('columntransformer-2',
        ColumnTransformer(remainder='passthrough',
                           transformers=[('encoder', OneHotEncoder(), 'Embarked')]))]
[190]: pipeline.steps[1]
[190]: ('columntransformer-2',
       ColumnTransformer(remainder='passthrough',
                          transformers=[('encoder', OneHotEncoder(), 'Embarked')]))
      1.2.4 Obsługa danych nienumerycznych
         • OrdinalEncoder lub LabelEncoder
         • OneHotEncoder
[95]: titanic = pd.read_csv('/home/tomaszd/codes/Python2021/labs02/titanic_train.
        ⇔tsv', delimiter='\t')
[97]: titanic.head()
[97]:
         PassengerId Survived Pclass \
                              0
                                      3
       0
                    1
                    2
       1
                              1
                                      1
                    3
                              1
       2
                                      3
       3
                                      1
                                      3
```

```
Name
                                                                  Sex
                                                                        Age
                                                                             SibSp \
       0
                                    Braund\t Mr. Owen Harris
                                                                 male
                                                                       22.0
                                                                                 1
       1
          Cumings\t Mrs. John Bradley (Florence Briggs T... female 38.0
                                                                               1
                                                                                 0
                                     Heikkinen\t Miss. Laina
                                                              female
                                                                       26.0
       2
       3
              Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                                              female 35.0
                                                                                 1
                                   Allen\t Mr. William Henry
                                                                                 0
                                                                 male 35.0
          Parch
                                       Fare Cabin Embarked
                           Ticket
                        A/5 21171
       0
              0
                                   7.2500
                                              {\tt NaN}
       1
              0
                         PC 17599 71.2833
                                              C85
                                                         C
       2
              0 STON/02. 3101282
                                                         S
                                    7.9250
                                              NaN
       3
              0
                           113803 53.1000 C123
                                                         S
              0
                           373450
                                    8.0500
                                              {\tt NaN}
                                                         S
[160]: from sklearn.preprocessing import OrdinalEncoder
       encoder = OrdinalEncoder()
       encoder.fit(titanic[['Sex']])
       print('klasy:', encoder.categories_)
       print(encoder.transform(titanic[['Sex']])[:10])
      klasy: [array(['female', 'male'], dtype=object)]
      [[1.]]
       [0.]
       [0.]
       [0.]
       [1.]
       [1.]
       [1.]
       Γ1. ]
       [0.]
       [0.1]
[128]: from sklearn.preprocessing import OneHotEncoder
       print(titanic[['Embarked']].loc[:3])
       encoder = OneHotEncoder(handle_unknown='ignore', sparse=False)
       encoder.fit(titanic[['Embarked']].dropna())
       print(encoder.categories_)
       print(encoder.transform(titanic[['Embarked']])[:3])
        Embarked
      0
               S
      1
               C
      2
               S
```

```
3     S
[array(['C', 'Q', 'S'], dtype=object)]
[[0. 0. 1.]
     [1. 0. 0.]
     [0. 0. 1.]]
```

1.3 Łączenie transformerów

- Transformery przetwarzają wszystkie kolumny jednocześnie.
- Jeżeli chcemy zastować dany transformer dla jednej cechy (kolumny), możemy użyć ColumnTransformer.

zadanie 3

```
[187]: array([[ 0. , 0. , 1. , 1. , 16.99, 2. ]])
```

2 Modele

- scikit-learn implementuje wiele podstawowych model do uczenia maszynowego:
 - modele regresyjne
 - k-najbliższych sąsiadów
 - SVM
 - i wiele innych.
- mają one wspólny interfejs: fit, predict, fit_predict.
- Wspólny interfejs pozwala na proste przełączanie się między modelami.

```
[169]: iris = datasets.load_iris()
       train_x, test_x, train_y, test_y = train_test_split(iris.data, iris.target,_
       →test_size=0.2, random_state=0)
      model = KNeighborsClassifier(5)
       model.fit(train_x, train_y)
      model.predict(test_x)
[169]: array([2, 1, 0, 2, 0, 2, 0, 1, 1, 1, 2, 1, 1, 1, 2, 0, 1, 1, 0, 0, 2, 1,
             0, 0, 2, 0, 0, 1, 1, 0])
[171]: from sklearn.svm import SVC
       models = [KNeighborsClassifier(5), SVC()]
       for model in models:
           model.fit(train_x, train_y)
           print(model.score(test_x, test_y))
      0.966666666666667
      1.0
[188]: df = pd.read_csv('/home/tomaszd/codes/Python2021/labs01/gapminder.csv')
       len(df)
[188]: 175
[186]: Zadanie 4:
       x = df.drop(['Country', 'life_expectancy'], axis='columns')
       y = df['life_expectancy']
       import numpy as np
       from sklearn.preprocessing import FunctionTransformer
       from sklearn.linear_model import LinearRegression
       col = ColumnTransformer(
```

2.1 Walidacja krzyżowa

• Czasami nasze dane są zbyt małe, żeby móc wydzielić zbiór testowy.

```
[194]: from sklearn.model_selection import cross_val_score
    iris = datasets.load_iris()
    knn = KNeighborsClassifier(n_neighbors=5)
    scores = cross_val_score(knn, iris.data, iris.target, cv=10, scoring='accuracy')
    print("Wynik walidacji krzyżowej:", scores)
```

```
Wynik walidacji krzyżowej: [1. 0.93333333 1. 1. 0.86666667 0.93333333 1. 1. 1. 1. ]
```